

# Análisis de señales ECG y detección de arritmias

1<sup>st</sup> Juan Camilo Carvajal Sierra  
Universidad de Antioquia  
Medellín, Colombia  
juanc.carvajal1@udea.edu.co

2<sup>nd</sup> Ana María Uribe Betancur  
Universidad de Antioquia  
Medellín, Colombia  
ana.uribeb@udea.edu.co

3<sup>rd</sup> Duvan Vega Cardona  
Universidad de Antioquia  
Medellín, Colombia  
duvan.vegac@udea.edu.co

**Abstract**—The study addresses the challenges of automatic arrhythmia detection from ECG signals by comparing R-peak detection techniques and HRV feature extraction for differentiating between cardiac arrhythmia types. It utilizes an ECG database and Python for analysis. The analysis includes statistical analysis of clinical data, evaluation of R-peak detection methods (NeuroKit2 and py-ecg-detectors), and non-parametric statistical tests to compare HRV features. The results highlight the prevalence of Sinus Bradycardia and the superior performance of Py-ECG in R-peak detection.

**Index Terms**—Arritmia, ECG, Variabilidad de la Frecuencia Cardíaca (HRV).

## I. INTRODUCCIÓN

Las enfermedades cardiovasculares (ECV) constituyen la principal causa de muerte a nivel mundial, representando aproximadamente el 32% de todas las muertes globales, con 17.9 millones de fallecimientos anuales según la Organización Mundial de la Salud [1]. En este contexto, la detección temprana y el diagnóstico preciso de arritmias cardíacas resultan fundamentales para reducir la mortalidad y mejorar la calidad de vida de los pacientes afectados. En las últimas décadas, diversos investigadores han propuesto métodos para la detección automática de arritmias mediante el análisis computacional de señales ECG. Lyon et al. [2] demostraron que los algoritmos de detección alcanzan sensibilidades superiores al 99% en condiciones ideales de laboratorio, aunque su rendimiento disminuye significativamente en presencia de ruido y artefactos. El presente estudio aborda estos desafíos mediante un análisis comparativo de técnicas de detección de picos R y extracción de características de HRV para la discriminación entre diferentes tipos de arritmias cardíacas.

## II. METODOLOGÍA

### A. Materiales y Herramientas

El estudio se basó en el análisis de la base de datos ChapmanECG [3], que contiene registros electrocardiográficos preprocesados y filtrados junto con información clínica asociada a los pacientes. Se utilizaron dos archivos principales: Diagnostics.xlsx, que incluye etiquetas de arritmias y características clínicas de los pacientes, y ECGDataDenoised.zip, que contiene las señales de ECG preprocesadas. El desarrollo y análisis de los datos se llevó a cabo empleando el lenguaje de programación Python (versión 3.0).

### B. Procedimiento

1) *Análisis Exploratorio y Selección de Datos*: Se realizó un análisis estadístico inicial de la información clínica para identificar patrones de prevalencia en las arritmias según género y edad. A partir de este análisis exploratorio, se seleccionó un subconjunto representativo de datos que permitiera una comparación equitativa entre diferentes tipos de arritmias para los análisis posteriores.

2) *Selección de la Herramienta de Detección de Picos R*: Para asegurar un enfoque robusto en la detección de picos R se evaluaron dos métodos de detección de picos R: uno basado en la función `ecgpeaks` de la librería `NeuroKit2` y otro utilizando la función `TwoAverageDetector` de la librería `py-ecg-detectors`.

3) *Análisis Estadístico*: Con la detección de picos R obtenida, se calculó la serie de intervalos RR para cada señal. Utilizando la librería `hrvanalysis`, se extrajeron características de variabilidad de la frecuencia cardíaca (HRV) en el dominio del tiempo mediante la función `get time domain features`. Se realizaron pruebas estadísticas no paramétricas para comparar las características de HRV entre los grupos de arritmias. Se empleó la prueba U de Mann-Whitney para comparaciones entre dos grupos, y la prueba Kruskal-Wallis para comparaciones múltiples. La elección de pruebas no paramétricas se basó en la falta de normalidad de los datos, verificada previamente mediante la prueba de Shapiro-Wilk, el uso de pruebas no paramétricas garantizó la validez estadística de los resultados en presencia de distribuciones no normales.

## III. RESULTADOS




Fig. 1: Distribución de la frecuencia de diferentes tipos de arritmias. El porcentaje indica la proporción de cada arritmia respecto al total de casos.

El análisis exploratorio de la base de datos de señales de ECG permitió identificar la distribución de las arritmias presentes en la población estudiada.

Como se muestra en la Fig. 1, la arritmia más prevalente fue la Bradicardia Sinusal (SB), con 3889 registros, representando el 44.09% del total de casos. Le siguió la Fibrilación Auricular (AFIB) con 1780 casos (20.18%). Otras arritmias como la Taquicardia Supraventricular (SVT), la Fibrilación Auricular (AF) y la Asistolia (SA) presentaron porcentajes menores. Las arritmias AVNRT, AVRT y SAAWR representaron menos del 1% de los casos (0.18%, 0.09% y 0.08%, respectivamente).

El análisis de prevalencia por género evidenció diferencias relevantes (Fig. 2). En ambos géneros, la Bradicardia Sinusal fue la más frecuente. Sin embargo, en hombres la segunda arritmia más común fue la Fibrilación Auricular, mientras que en mujeres fue la Taquicardia Sinusal.




Fig. 2: Frecuencia de arritmias por género: hombres (izquierda) y mujeres (derecha).

Respecto a la distribución por grupo etario (Fig. 3), se observó una mayor diversidad de arritmias en los grupos de jóvenes adultos (18-35 años), adultos maduros (36-60 años) y adultos mayores (61-90 años). En contraste, los grupos de niños (0-5 años), adolescentes (6-17 años) y ancianos longevos (menos de 90 años) presentaron menor representación, lo cual puede afectar la generalización de los resultados debido al tamaño reducido de muestra en estos rangos.




Fig. 3: Distribución de arritmias por grupos etarios.

En cuanto a la comparación de métodos de detección de picos R, se observó que Py-ECG detectó en promedio

una mayor cantidad de picos R en ambos tipos de arritmia seleccionados (AFIB y SB), como se visualiza en los boxplots de la Fig. 4. En AFIB, Py-ECG mostró una mejora promedio aproximada del 5% en la detección de picos R respecto a NeuroKit2, mientras que en SB la mejora fue cercana al 10%. En algunos casos, se registraron diferencias relativas de hasta 37.5% a favor de Py-ECG.




Fig. 4: Cantidad de picos R detectados por los métodos NeuroKit2 y PyECG en registros de AFIB y SB.

Posterior a la selección de la herramienta de detección de picos R, se calcularon las métricas de variabilidad de la frecuencia cardíaca (HRV), se procedió a comparar las características entre los diferentes grupos de arritmias mediante pruebas estadísticas no paramétricas. Para cada métrica, se construyó una matriz de comparación en la que cada celda representaba el valor-p de la prueba U de Mann-Whitney entre dos tipos de arritmia, acompañado de la hipótesis aceptada (nula o alternativa). En la Fig. 5 se muestra un ejemplo de esta matriz para la métrica SDNN.



Fig. 5: Matriz de valores-p para las comparaciones de Mann-Whitney utilizando la métrica SDNN.

De forma resumida, los resultados de todas las comparaciones se presentan en la Tabla I. En esta tabla se observó que la métrica "range nni" demostró la mejor capacidad discrimi-

natoria, logrando diferencias estadísticamente significativas en el 100% de las comparaciones entre los pares de arritmias. Esta métrica presentó el p-valor global más bajo ( $1.02e-287$ ) y un promedio de p-valores ( $1.90e-03$ ) inferior al promedio general de todas las métricas ( $2.43e-02$ ).

Otras métricas que mostraron un alto porcentaje de discriminación (mayor al 95%) fueron sdnn, sdsd, mean nni, nni 50, rmssd y mean hr. En particular, sdnn presentó un p-valor promedio de  $4.40e-03$ , destacándose entre las métricas con mejor desempeño.

TABLE I: Resumen de comparaciones estadísticas por métrica (Mann-Whitney).

Métrica	% Rech.	Prom. p-val	Prom. p-val (rech.)	p-val Mín.	p-val Máx.
mean_nni	95.24	1.76e-02	2.08e-05	2.65e-237	3.70e-01
sdnn	95.24	4.40e-03	3.92e-10	2.21e-223	9.25e-02
sdsd	95.24	1.22e-02	1.61e-03	7.56e-210	2.23e-01
nni_50	95.24	3.41e-02	2.73e-04	1.07e-208	7.10e-01
pnni_50	90.48	3.84e-02	1.70e-03	1.12e-208	6.35e-01
nni_20	85.71	5.97e-02	1.38e-03	7.99e-186	8.99e-01
pnni_20	85.71	3.45e-02	2.43e-04	3.99e-262	4.71e-01
rmssd	95.24	1.09e-02	4.75e-04	1.67e-211	2.19e-01
median_nni	95.24	1.24e-02	3.02e-06	2.55e-237	2.61e-01
range_nni	100.00	1.90e-03	1.90e-03	1.02e-287	3.99e-02
cvsd	85.71	1.25e-01	1.21e-03	3.02e-208	9.58e-01
cvnni	85.71	9.13e-02	2.03e-03	4.77e-210	9.34e-01
mean_hr	95.24	1.84e-02	1.31e-07	2.65e-237	3.86e-01
max_hr	85.71	6.58e-02	1.86e-03	2.50e-193	9.23e-01
std_hr	85.71	7.85e-02	3.68e-04	2.09e-204	6.92e-01

Finalmente, se realizó la prueba de Kruskal-Wallis para comparar simultáneamente más de dos grupos utilizando cada una de las métricas. En la Tabla II se resumen los resultados de esta prueba, presentando el estadístico H, el valor-p y la hipótesis aceptada para cada métrica.

TABLE II: Resultados de la prueba de Kruskal-Wallis para las métricas de HRV.

Métrica	Estadístico H	Valor p	Hipótesis Aceptada
mean nni	5.66e+03	0.00e+00	H1: Hay diferencias
sdnn	3.29e+03	0.00e+00	H1: Hay diferencias
sdsd	3.01e+03	0.00e+00	H1: Hay diferencias
nni 50	3.73e+03	0.00e+00	H1: Hay diferencias
pnni 50	3.49e+03	0.00e+00	H1: Hay diferencias
nni 20	3.27e+03	0.00e+00	H1: Hay diferencias
pnni 20	2.79e+03	0.00e+00	H1: Hay diferencias
rmssd	3.05e+03	0.00e+00	H1: Hay diferencias
median nni	5.76e+03	0.00e+00	H1: Hay diferencias
range nni	2.85e+03	0.00e+00	H1: Hay diferencias
cvsd	2.61e+03	0.00e+00	H1: Hay diferencias
cvnni	2.27e+03	0.00e+00	H1: Hay diferencias
mean hr	5.20e+03	0.00e+00	H1: Hay diferencias
max hr	7.28e+02	5.61e-154	H1: Hay diferencias
std hr	1.71e+03	0.00e+00	H1: Hay diferencias

Se observó que en 14 de las 15 métricas analizadas el valor-p fue reportado como  $0.000000e+00$ , lo que se atribuye a la limitación numérica en la precisión de los cálculos computacionales, no a una falta de significancia estadística.

Posteriormente, se aplicó la prueba post-hoc de Dunn para identificar entre qué pares de grupos existían diferencias significativas. Los resultados se resumen en la Tabla III, donde se evidenció que las métricas sdnn y range nni lograron diferencias significativas en el 95.24% de las comparaciones realizadas.

TABLE III: Resultados de comparaciones post-hoc de Dunn por métrica.

Métrica	% Comparaciones Significativas
sdnn	9.52e+01
range nni	9.52e+01
nni 20	9.05e+01
nni 50	9.05e+01
pnni 50	8.57e+01
pnni 20	8.57e+01
mean nni	8.57e+01
mean hr	8.57e+01
median nni	8.57e+01
cvnni	8.57e+01
sdsd	8.10e+01
cvsd	8.10e+01
rmssd	8.10e+01
max hr	7.62e+01
std hr	7.62e+01

## IV. DISCUSIÓN

### A. Exploración y selección de datos

Según lo observado previamente, se identificó que los rangos de edad que proporcionan la mayor cantidad de datos comparables abarcan desde los 18 hasta los 90 años, siendo los grupos de 36 a 60 años y de 61 a 90 años los más representativos en términos de volumen. En cuanto a las arritmias, se decidió excluir a los pacientes con Atrioventricular Nodal Reentrant Tachycardia (ANRT), Atrioventricular Reentrant Tachycardia (AVRT) y Sinus Arrhythmia with Atrial Wandering Rhythm (SAAWR), debido a que el número de registros en estos grupos resulta ser extremadamente reducido en comparación con el resto de los datos disponibles.

Al explorar la base de datos, se logra establecer una relación entre distintos tipos de arritmias y grupos poblacionales específicos. En términos generales, las arritmias que presentan mayor prevalencia en la población analizada son la Bradicardia Sinusal (SB), la Fibrilación Auricular (AFIB) y la Taquicardia Sinusal (ST), condiciones que suelen estar asociadas principalmente a enfermedades cardiovasculares y a hábitos de vida poco saludables mantenidos a lo largo del tiempo. La bradicardia sinusal (SB), en particular, tiende a manifestarse como consecuencia de un aumento en el tono vagal, algo frecuente durante el sueño o en personas con un alto nivel de entrenamiento físico; sin embargo, también puede ser provocada por disfunciones del nodo sinusal, hipotiroidismo o efectos secundarios de ciertos medicamentos como los betabloqueadores [4]. En contraste, la fibrilación auricular (AFIB) suele originarse a partir de factores como la hipertensión arterial, las enfermedades valvulares, el envejecimiento del corazón o trastornos como la insuficiencia cardíaca y el hipertiroidismo; además, su aparición puede estar relacionada con el consumo excesivo de alcohol. En cuanto a la taquicardia sinusal (ST), generalmente se presenta como una respuesta fisiológica normal frente a estímulos como el ejercicio, la fiebre, la ansiedad o el dolor, aunque en ocasiones puede ser desencadenada por patologías como la anemia, la hipovolemia o las enfermedades pulmonares. El último caso de estudio es la Taquicardia Atrial (AT) la cual es un tipo de arritmia en la que el corazón late mucho más rápido de lo normal, en un

rango de 100 a 250 latidos por minuto (lpm) [5]. Esta arritmia es común y generalmente no peligrosa, pero puede afectar a personas de cualquier edad. Al analizar las condiciones de los pacientes, es importante considerar las diferencias de edad para asegurar que las condiciones sean consistentes en todo el grupo, garantizando resultados representativos. La incidencia de la arritmia está directamente relacionada con la edad, lo que concuerda con la literatura y valida la coherencia de los datos.

Las causas asociadas a cada arritmia explican su mayor prevalencia en adultos y en individuos de género masculino, dado que factores como el consumo de alcohol, el tabaquismo, el sedentarismo y una alimentación inadecuada tienden a ser más frecuentes en este grupo. Además, las enfermedades cardiovasculares relacionadas también muestran una mayor incidencia en hombres. No obstante, es importante señalar que la Bradicardia Sinusal no siempre se considera una arritmia patológica, por lo que resulta necesario complementar los estudios realizados con fundamentos médicos adicionales que permitan una interpretación más precisa.

#### B. Variabilidad de la frecuencia cardíaca (HRV) y otros índices ECG

La detección de picos R en las señales se realizó utilizando el detector Hamilton, un algoritmo clásico basado en una serie de filtros de paso banda, diferenciadores, funciones de energía y umbrales adaptativos que permiten una detección robusta de complejos QRS en tiempo real, incluso en condiciones de ruido moderado [6]. Posteriormente, se calcularon métricas de variabilidad de la frecuencia cardíaca (HRV) mediante la librería *hrvanalysis*, obteniendo parámetros de dominio temporal y frecuencial. Se puede observar en la tabla algunos resultados de interés en la diferenciación de las arritmias.

TABLE IV: Parámetros de interés resultantes de la detección con Py-ECG-Detectors.

Arritmia	mean_nni	RMSSD	SDNN	pNN50	mean_HR	R_peaks
AF	571	137	105	49	118	18,7
AFIB	663	215	162	76	102	15,7
AT	543	143	101	46	121	19
SA	825	152	135	56	77	12,2
SB	997	227	207	43	68	10,1
ST	546	51	37	23	112	18,2
SVT	380	42,4	28	15	162	26

Estos parámetros incluyen el intervalo NN promedio (mean nni), que refleja la duración media entre latidos normales consecutivos, y la frecuencia cardíaca media (mean HR), que varía notablemente entre arritmias. Las métricas de variabilidad de la frecuencia cardíaca (HRV), como RMSSD, SDNN y pNN50, ofrecen información sobre las fluctuaciones en los intervalos entre latidos, donde valores más altos generalmente indican una mayor variabilidad en la función cardíaca [7]. Las relaciones encontradas entre las arritmias son coherentes con lo esperado, donde la taquicardia supraventricular (SVT) presenta la frecuencia más alta (162 lpm), y la bradicardia sinusal (SB) presenta la más baja (68 lpm), este parámetro se relaciona directamente con los picos R detectados y el intervalo medio entre estos.

La precisión de las métricas de HRV depende directamente de la precisión de la detección de los picos R. Si bien el algoritmo de Hamilton es eficiente y adecuado para la implementación en tiempo real, tiene limitaciones. Su rendimiento puede degradarse en presencia de ruido significativo, como el artefacto muscular o la interferencia de la línea eléctrica, o en señales con morfologías QRS inusuales, como las observadas en ciertas arritmias. La complejidad de las arritmias, como la fibrilación auricular, donde los picos R pueden ser irregulares en amplitud y duración, plantea un desafío particular para la detección y la hace más sensible a errores. Si el algoritmo Hamilton tiene dificultades con ciertas arritmias debido a la irregularidad de los picos R, las métricas de HRV resultantes (RMSSD, SDNN, pNN50) pueden no reflejar con precisión la verdadera variabilidad de la frecuencia cardíaca. En arritmias con morfologías QRS muy distorsionadas o de baja amplitud, el algoritmo podría pasar por alto algunos picos R, lo que afectaría el cálculo de la frecuencia cardíaca y otras métricas.

Además, la necesidad de ajustar cuidadosamente los parámetros del algoritmo, incluidos los umbrales adaptativos, puede ser un inconveniente. La configuración óptima puede variar entre pacientes y tipos de señales de ECG, lo que requiere una calibración y validación cuidadosas para garantizar una detección precisa de los picos R [8].

#### C. Comparación de características (HRV) entre grupos

El análisis estadístico realizado mediante las pruebas de U de Mann-Whitney, Kruskal-Wallis y la prueba post-hoc de Dunn ha permitido identificar métricas de HRV con alta capacidad discriminatoria entre distintos tipos de arritmias en las señales de ECG preprocesadas.

Primero, la prueba U de Mann-Whitney mostró que la métrica *range nni* (rango de los intervalos NN) es la que mejor distingue entre los pares de arritmias analizados, alcanzando un 100% de discriminación significativa. Este hallazgo es consistente con investigaciones previas que han reportado que métricas basadas en la dispersión de intervalos cardíacos, como *range nni* y SDNN, son altamente sensibles para detectar disfunciones autonómicas asociadas a distintos tipos de arritmia [9]. Estos hallazgos concuerdan con lo reportado por Acharya et al. [10], quienes demostraron que la variabilidad en los intervalos NN constituye uno de los indicadores más sensibles para la identificación de alteraciones del ritmo cardíaco. La capacidad discriminatoria del *range nni* puede explicarse por la naturaleza de las arritmias estudiadas, particularmente la Bradicardia Sinusal (SB) y la Fibrilación Auricular (AFIB), que presentan patrones distintivos de variabilidad temporal entre latidos consecutivos.

La prueba de Kruskal-Wallis corroboró la existencia de diferencias estadísticamente significativas entre grupos para todas las métricas analizadas, reforzando la robustez de los hallazgos. Los resultados de las pruebas post-hoc de Dunn refuerzan el valor discriminatorio de las métricas *sdnn* y *range nni*, ambas logrando identificar diferencias significativas en el 95.24% de las comparaciones entre pares de arritmias. Esto sugiere que estas métricas no solo discriminan efec-

tivamente en comparaciones binarias (Mann-Whitney) sino también en escenarios de comparaciones múltiples ajustadas por corrección.

Los resultados encontrados tienen implicaciones relevantes. En primer lugar, demuestran que algunas métricas de HRV pueden ser empleadas para mejorar los sistemas automáticos de clasificación de arritmias, lo que resulta particularmente útil en el desarrollo de herramientas de diagnóstico asistido por computador (CAD) en cardiología. Actualmente, empresas como Viatom Technology y Cardiomatics ofrecen soluciones comerciales basadas en análisis HRV, y los hallazgos de este estudio podrían ser implementados para mejorar los algoritmos de diferenciación automática de arritmias que estas plataformas utilizan [11], [12].

Viatom Technology, que ofrece la herramienta AI-ECG, es plataforma automática de análisis y diagnóstico de electrocardiogramas permite la recolección de datos en múltiples centros, el diagnóstico remoto y el tratamiento jerárquico. AI-ECG puede ser utilizada para asistir en la construcción de la informatización de la red de ECG del hospital, facilitar el intercambio de datos e informes de ECG en todo el hospital, conectar instituciones médicas y proporcionar soluciones integrales de ECG para centros de dolor torácico, alianzas médicas y la construcción de telemedicina [11].

Cardiomatics por su parte, una empresa dedicada al desarrollo de software de interpretación de ECG basado en inteligencia artificial, lo que representa un avance importante en los diagnósticos cardíacos. La plataforma permite a los médicos obtener información rápida y precisa sobre la salud del corazón mediante la detección de anomalías y la elaboración de informes detallados. Este software facilita la identificación de alteraciones en el ritmo cardíaco, lo que permite una intervención temprana para prevenir resultados adversos. A través de su capacidad de análisis, se mejora la precisión en la detección de problemas cardíacos, especialmente en casos con síntomas intermitentes, típicos de enfermedades cardiovasculares [12].

## V. CONCLUSIONES

- El estudio confirmó la alta prevalencia de la Bradicardia Sinusal dentro de la población analizada, con un 44.09% de los registros correspondientes a esta arritmia. Este hallazgo subraya la importancia de dedicar atención especial a la detección y el análisis preciso de esta condición en las señales de ECG, dado su predominio significativo en el conjunto de datos estudiado.
- La comparación entre los métodos de detección de picos R reveló que Py-ECG generalmente detectó una mayor cantidad de picos R en comparación con NeuroKit2. Esto sugiere que Py-ECG podría ofrecer una mayor sensibilidad en la identificación de eventos cardíacos, capturando picos que NeuroKit2 podría pasar por alto. En particular, Py-ECG mostró una mejora de entre el 5% y 10% dependiendo de la arritmia analizada.
- Las métricas de Variabilidad de la Frecuencia Cardíaca (HRV) demostraron un potencial significativo para dis-

criminar entre diferentes tipos de arritmias. En particular, la métrica "range nni" mostró la mejor capacidad discriminatoria, logrando diferencias estadísticamente significativas en el 100% de las comparaciones entre los pares de arritmias, con el p-valor global más bajo y un promedio de p-valores inferior al promedio general de todas las métricas.

## VI. REFERENCIAS

- [1] World Health Organization, "Cardiovascular diseases (CVDs)," WHO Fact Sheet, 2021. [Online]. Available: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))
- [2] A. Lyon, A. Mincholé, J. P. Martínez, P. Laguna, and B. Rodriguez, "Computational techniques for ECG analysis and interpretation in light of their contribution to medical advances," *Journal of The Royal Society Interface*, vol. 15, no. 138, 2018.
- [3] J. Zheng, "ChapmanECG". figshare, 30-Jun-2019, doi: 10.6084/m9.figshare.c.4560497.v1.
- [4] Instituto Mexicano del Seguro Social, Guía de Práctica Clínica: Diagnóstico y Tratamiento del Síndrome del Seno Enfermo, Catálogo maestro de guías de práctica clínica: IMSS-569-12, México, 2012.
- [5] "Atrial tachycardia - Symptoms and causes," Mayo Clinic. <https://www.mayoclinic.org/diseases-conditions/atrial-tachycardia/symptoms-causes/syc-20573298>
- [6] "A new method for evaluating ECG signal quality for multi-lead arrhythmia analysis," *IEEE Conference Publication — IEEE Xplore*. <https://ieeexplore.ieee.org/document/1166713>
- [7] F. Shaffer and J. P. Ginsberg, "," *Frontiers in Public Health*, vol. 5, Sep. 2017, doi: 10.3389/fpubh.2017.00258.
- [8] R. Tiwari, R. Kumar, S. Malik, T. Raj, and P. Kumar, "Analysis of heart rate variability and implication of different factors on heart rate variability," *Current Cardiology Reviews*, vol. 17, no. 5, Jan. 2021, doi: 10.2174/1573403x16999201231203854.
- [9] F. Shaffer and J. P. Ginsberg, "An overview of heart rate variability metrics and norms," *Frontiers in Public Health*, vol. 5, Sep. 2017, doi: 10.3389/fpubh.2017.00258.
- [10] U. R. Acharya, K. P. Joseph, N. Kannathal, C. M. Lim, and J. S. Suri, "Heart rate variability: a review," *Medical Biological Engineering Computing*, vol. 44, no. 12, pp. 1031–1051, Nov. 2006, doi: 10.1007/s11517-006-0119-0.
- [11] Vicky, "AI-ECG Intelligent ECG Interpretation Solution — Viatom," Viatom, May 31, 2023. <https://www.viatomcare.com/intelligent-ecg-interpretation-solution/>
- [12] Cardiomatics, "Cardiomatics - Advanced AI for fast ECG interpretation," Cardiomatics, Apr. 23, 2025. <https://cardiomatics.com/>